

Introduction convolutional Neural nets

(CNNs)

المقدمة: السُّبُكَاتِ الْعُقُوبِيَّةِ الْأَلْتَفَافِيَّةِ CNN: تَسْتَهِمُ بِكُثُرَةٍ فِي تَطْبِيقَاتِ الْتِبْصِيرِ الْأَبْصَرِيِّيِّ وَالْتَّعْلُمِ الْعُقُوبِيِّ، وَتُمْكِنُ اسْتَهِنَانِهَا أَوْلَى مَرَّةً فِي تَفْبِيقِ بِسِطِّ لَكْنَفِ الْأَرْقَامِ بِنَسْخَةٍ 0 مِنْ 9، وَالْكِتَابَةِ بِخطِ الْيَدِ فِي عَامِ 1998 مِنْ قِبَلِ الْفَالْمُ.

LeCUN

Voice \rightarrow text \rightarrow CNN \rightarrow 0, 1, 2

* Hand written digit classification

conv-1: (5x5) max-pooling

kernel (2x2)



Input n_1 channel n_1 channel n_2 channel n_2 channel

$(28 \times 28 \times 1)$ $(24 \times 24 \times n_1)$ $(12 \times 12 \times n_1)$ $(8 \times 8 \times n_2)$ $(4 \times 4 \times n_2)$

\Rightarrow الـ input صورة أبيض وسود للأرقام

الـ input هو مجموع (28x28) دالة n_1 و (12x12) دالة n_2 .

على عدد العناصر

\Rightarrow لدينا طبقتين conv1 و conv2 و عدد 8 "out" و عدد 16 "in".

و المكون الذي له الـ conv1 تفعيل أي هو المكون المترافق عليه

و بما أن الدالة هي صورة رقم (2) أي الـ 2 (2) حرف

الـ 2 الذي يعطي أعلى تفعيل

مواصفات الـ CNN :

1. تأقلم بين احتمال البنية المحلية والبيانات المترددة المتباينة.

2. غير كاملة الدقة.

3. مداركة الأدوات.

4. تعلم قيم كل فلتر معنون بالفلاتر والتي سيتم تطبيق عملية الفيما

بينها وبين الصورة لتحديد درجة التباين بين المزدوجة وبينها.

5. وكلما كانت القيمة كبيرة كلما كان هناك تباين.

* consider learning an image : تعلم الصورة :

يعنى النادع تكون أصيف بكثير من العودة بكمالها مثلاً منقار

العصفوري أصيف من صورة العصفوري كاملة.

ولذلك يجب تحريم فلاتر يعدل على كل المنقار صيغ أو زاد

المبكرة يتم اختيارها بشكل عشوائي و بذلك الأوزان في قيمة

الفلتر ومن ثم يتم فلترة الصورة التدريجياً فضلاً عنها قيم متأخرة

للفلتر الذي سيكتفى ويحدد منقار في الصورة أو لا من

فلتاً إيجاباً عملية الفي بين الصورة والفلتر وكلما كانت نتيجة

(التي) أكبر كلما كان التباين بين الفلتر والصورة أكبر.

الذى كان لديه صدر بين العصفوريين و مكان المنقار في كل

صورة مختلف فلنuspئ ذلك على عملية الاستفادة من

لين يؤمن ذلك على عملية الاستفادة لأننا نقوم بتحريك

الفلتر على كامل الصورة وبالتالي يتم اكتساب المنقار

بعضها كان ملائمه.

...CNN...

CNN في سلسلة عمليات لتوسيع كلها بصفتها جنباً

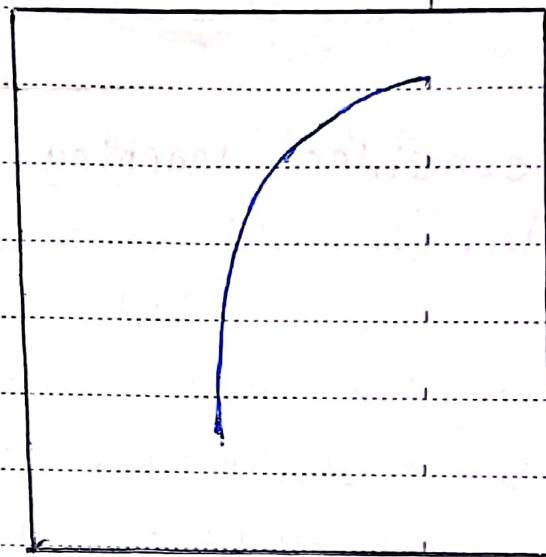
Convolutional طبقه و لایهی convolutional

filters على عدد من الـ

متلاز... لدى فلتر ٧x٧ لـ(٢٠) مللي متر فلكان الفنتي

نطع ٣٥ . والباقي أعياد :

O	O	O	O	O	30	O
O	O	O	O	30	O	O
O	O	O	30	O	O	O
O	O	O	30	O	O	O
O	O	O	30	O	O	O
O	O	O	30	O	O	O
O	O	O	30	O	O	O
O	O	O	O	O	O	O



تمثيل الفلت بـ كل يكل

وَلِيَكُنْ لَدَنَا الصِّرَاطُ الْمُتَقَدِّمُ

بيانات توافق منحى فاصل تطبيق

الفلتر الدلفي ذكره على النطافتين

المحدثين في الصورة (القيادة)

والي) ایجاد کل صنعا

مساوٍ للأبعاد الفلكية

١١) نلاحظ أن التباين بين الفاتح والمتónica لا يذكر بين

النهاية بين الفلك والمنطقة 2

التاريخ

0	0	0	0	0	0	30
0	0	0	0	50	50	50
0	0	0	20	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0

0	0	0	0	0	30	0
0	0	0	0	30	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0

منطقة ١ من مراة القارئ

الفلت المطبق

$$\Rightarrow \text{Multiplication and summation} = (50 * 30) + (50 * 30) \\ + (50 * 30) + (20 * 30) + (50 * 30) = 6600$$

وهذه الرقم هو قيمة كبيرة.

نطبق الفلت على المنطقة (2) من صورة الغراء:

0	0	0	0	0	0	60
0	40	0	0	0	0	0
40	0	40	0	0	0	0
40	20	0	0	0	0	0
0	50	0	0	0	0	0
0	0	50	0	0	0	0
25	25	0	50	0	0	0

0	0	0	0	0	0	30
0	0	0	0	30	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0

$$\text{Multiplication and summation} = 0 \quad \text{القيمة قليلة}$$

لعدم وجود تباين بين للفلت والمنطقة (2)

التاريخ:

جزء 1 جزء 2

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

Image : 6×6

الصورة الأصلية

Filter 1

1	-1	-1
-1	1	-1
-1	-1	1

filter 2

-1	1	-1
-1	1	-1
-1	1	-1

عندئي صورة أصلية أبعادها 6×6 دلدينا فلتر أول أبعاده

3×3 دللت على أبعاده

نطبق الفلتر الأول على كل جزء من الصورة أبعادها 3×3 ثم

نتصل بخواص (1) للجزء الثاني من الصورة.

ونقدم بعمليه بدأه بعن الجزء (1) عن الصورة الأصلية

وبين الفلتر الأول:

$$(1 * 1) + (-1 * 0) + (-1 * 0) + (0 * 1) + (1 * 1)$$

$$+ (-1 * 0) + (-1 * 0) + (-1 * 0) + (1 * 1) = 3$$

نرجع الفلتر بعمليه (1) ونجري عملية بدأه بعن

جزء (2) والفلتر:

0	0	0
1	0	0
0	1	1

$$(1 * 0) + (-1 * 0) \\ = +(-1 * 0) + (+1 * 1) \\ + (1 * 0) + (-1 * 0) \\ + (-1 * 0) + (-1 * 1) \\ + (1 * 1) = -1$$

التاريخ:

وهكذا! هنا يرى الـ filter على كامل صورة المدخلة، وأكبر
ناتج بداء بين filter 1 و filter 2، أي دليل على وجود
تشابه بين الفلتر وصفة الصورة. وفي الحقيقة في filter 2
في النهاية سيكون لدى مصفوفتين:

ال الأولى ناتجة عن تطبيق الـ filter 1 على الصورة 5×5 .

الثانية ناتجة عن تطبيق الـ filter 2 على الصورة 5×5 .

Feature map.

لوكات لدينا صورة أبعادها (7×7) ، والفلتر أبعادها (3×3) . Note

$P = 1$ و $S: stride = 1$ (المقدار الإضافي) ولا

$N: size of image = 7$ ، $S: stride = 1$ أي،
Filter size = 3، amount of padding = 1

output size = 7، أي حجم إلى 7.

$$\text{output size: out} = \frac{N - F + 2P}{S} + 1$$

$$\text{output size} = \frac{7 - 3 + 2(1)}{1} + 1 = 7$$

out: 7×7

* zero padding

تستخدم الكوادو الصفرى لاما لحافظة على الحجم الأصلى للصورة

أو لزيادة حجم الصورة ولما يكتب الكوادو الصفرى معنا العلاقة:

$$(F-1)/2$$

F. فرج الفرات

$F = 3 \Rightarrow$ zero padding with 1

$F = S \Rightarrow$ zero padding with 2

$F = 7 \Rightarrow$ zero padding with 3

* Color image : RGB 3 channels

فـٰ حالـاـ كانـ لـدـيـنـاـ صـورـةـ R~G~Bـ مـلـوـنـةـ أيـ يـبـ تـبـيـلـ الصـورـةـ

بِلَاتْ (Billets) مصْنُوعَاتٍ زَدَاهُوَاتٍ R وَزَدَاهُوَاتٍ لَّهُ زَدَاهُوَاتٍ (Billets)

و لم يمكنا إيجاد (3×3) filter معرفة (5×5)

وبالتالي `Zero padding` لـ `الإطار العصري` `الدايم` `ما فته`

$\text{strides} = 2$ (الخطوة وبعدها) $(3-1) \cdot 12 = 1$ خطوة

وطبقنا على الصورة \mathbf{w}_0 و \mathbf{w}_1 كلتاً في $\mathcal{C}_{\text{bias}}$

$$b_1 = \partial \text{ over } w_1 \text{ and } b_0 = 1 \text{ over } w_0.$$

المصروفقة الأدكى بعن المفورة

○	○	○	○	○	○	○
○	1	1	0	1	0	0
○	1	2	2	0	2	0
○	0	0	0	1	0	0
○	0	2	1	2	0	0
○	1	2	0	0	1	0
○	0	0	0	0	0	0

wa

1	-1	1
1	-1	-1
1	1	1

الصورة الـ α -صلبة بعد $\frac{1}{2}$ دورة

بالناتي تجي عملية مداد بين zero padding

الجزء (١) من المعرفة الأولى (معرفة R) بالعوادة

$$0+0+0+0+(-1^{\neq}1)+(-1^{\neq}1) : \text{ما يلي} \\ +0+(1^{\neq}1)+(1^{\neq}2) = -1-1+1+2 = 1$$

التاريخ:

جزء ١

0	0	0	0	0	0	0
0	2	0	1	0	1	0
0	0	0	0	0	0	0
0	0	1	0	1	2	0
0	2	2	0	0	1	0
0	2	0	2	1	0	0
0	0	0	0	0	0	0

1	1	0
0	0	1
-1	-1	0

الفلتر المطبق على المصفوفة
الثانية من الصورة.

المصفوفة الثانية من الصورة

الأصلية (مصفوفة G) ونطبيق عملية جداء بين:

الجزء ٢ من الصورة وبين W2:

$$0+0+0+0+0+0+0+0=0$$

0	0	0	0	0	0	0
0	1	1	0	1	2	0
0	0	0	1	2	2	0
0	0	1	0	0	2	0
0	1	0	1	0	1	0
0	2	2	0	0	0	0
0	0	0	0	0	0	0

-1	1	0
0	0	1
-1	-1	1

الفلتر المطبق على
المصفوفة الثالثة من
الصورة.

المصفوفة الثالثة من الصورة

الأصلية (مصفوفة G)

=> عملية الجداء :

$$0+0+0+0+0+1+0+0+0=1$$

=> العنف الأدولي بـ مصفوفة G :

التاريخ:

$$1 + 0 + 1 + 1 = 3 \rightarrow \text{الإذار}$$

ناتج تبديل

الفتر

على كل المصفوفة

الأدلة

المصفوفة الثالثة

ناتج الفلت w_3 بمقدار (2) بكل مصفوفة من

المصفوفات R و G و B ونطبق نفس المفهوم السابقة

لحصل على مصفوفة المزاع:

3	7	0
3	4	0
4	11	4

نطبق w_4 على كل مصفوفة من المصفوفات

0	1	-1
0	-1	0
0	-1	1

-1	0	0
1	-1	0
+1	-1	0

-1	1	-1
0	-1	-1
1	0	0

للمصفوفة الثالثة w_3 للمصفوفة الأولى

ونقوم بباقي العمليات في الفلت w_3 حيث نقدم بعمليه جداء

بين كل مجزء من العمود مع w_3 (الفلت) لعمل على مصفوفة

المزاع: دعمنا أن الإزاحة $(B \setminus S) = 0$

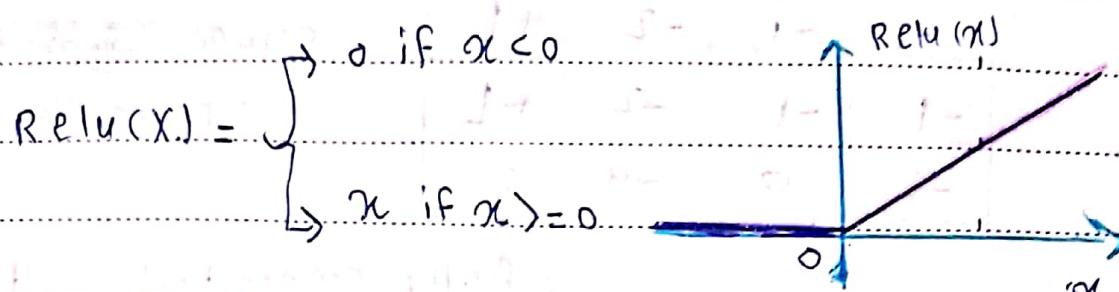
+4	6	-1
3	0	1
1	-2	-3

التاريخ: / /

توابع التفعيل:

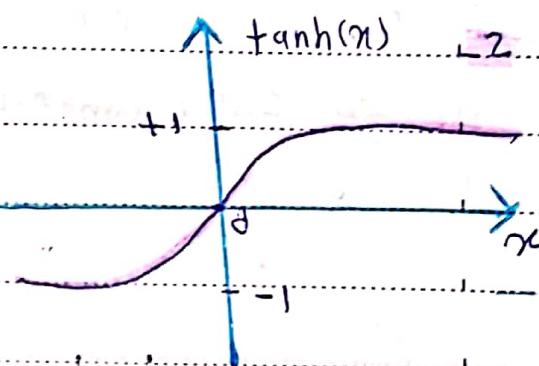
: مفهوم (ReLU) Rectified Linear Unit

ReLU: $f(x) = \max(0, x)$ الخودة الخطية



Thanh(X)

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$



convolution vs Fully connected:

: Convolution

1	0	0	0	0	0	1
0	1	0	0	1	0	
0	0	1	1	0	0	
1	0	0	0	1	0	
0	1	0	0	1	0	
0	0	1	0	1	0	

Filter 1

Filter 2

ولدينا Filter1 Filter2

سيتم تطبيقها على الصورة

الصورة الصلبة

الصلبة

التاريخ:

وستكون نتيجة تطبيق الفلتر الأول على العريضة الأصلية:
بالناتي فـ $\frac{1}{3}$ مثلاً في عملية الـ

-1	-1	-1	-1
-1	-1	-2	+1
-1	-1	-2	+1
-1	0	-4	3

in convolution

filter تطبيق عملية

على سمات مثلاً

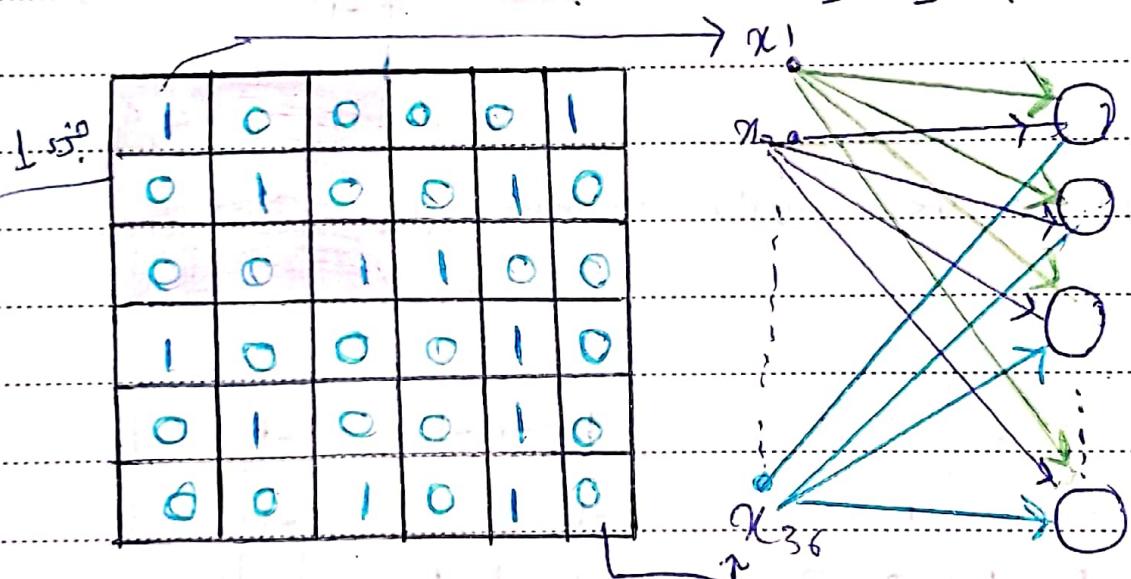
: fully connected

لدينا صورة 6×6 عند تطبيق الـ Fully connected

لدينا (36 دخل) لأن كل عصبون

يكتب في العريضة (ودفل) ويتم ضرب كل دفل بوزن كل

عصبون وبالتالي يكون لكل عصبون 36 وزن



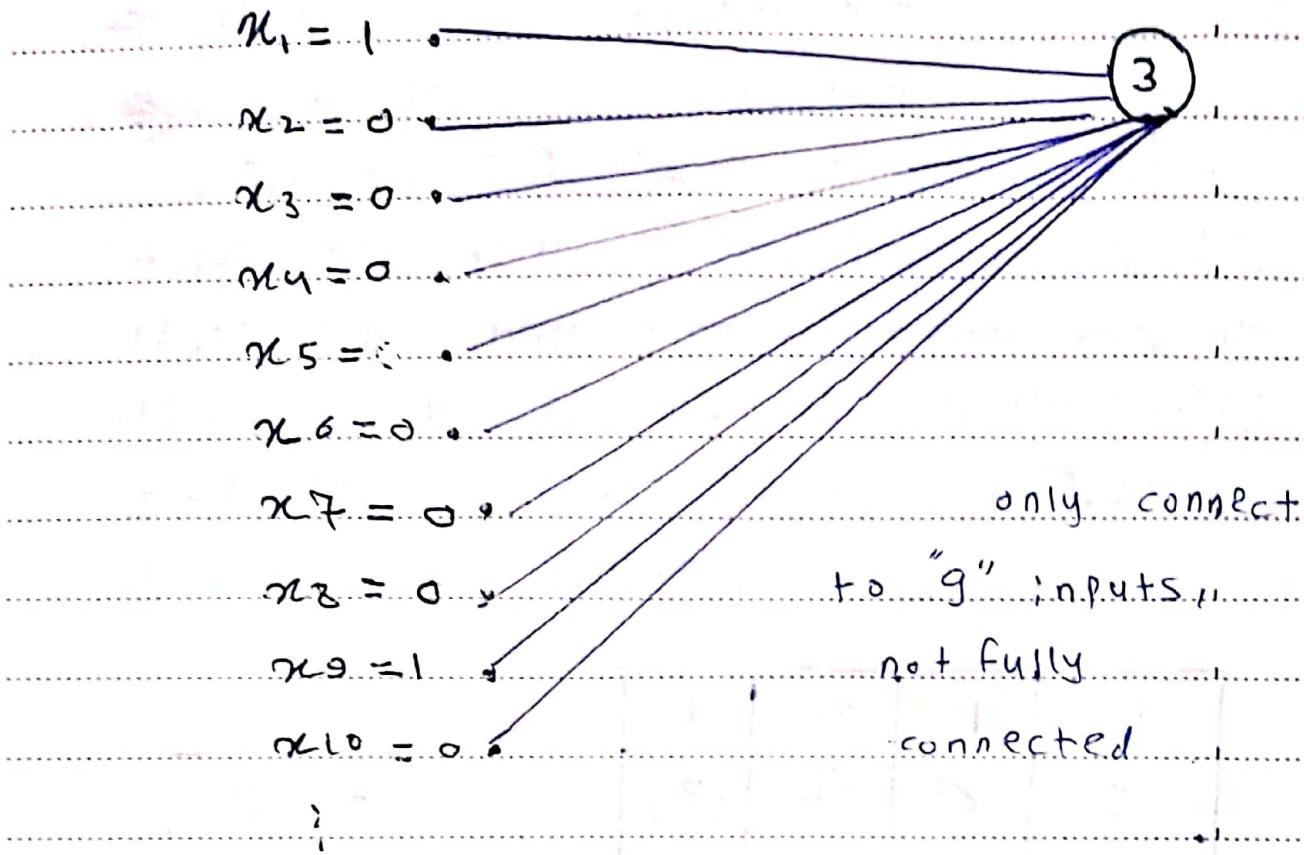
ولو طبقنا الفلتر التالي على العريضة (التي الأدلة من العريضة)

ستكون مصفرة المرة

1	-1	-1
-1	1	-1
-1	-1	1

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

w_1



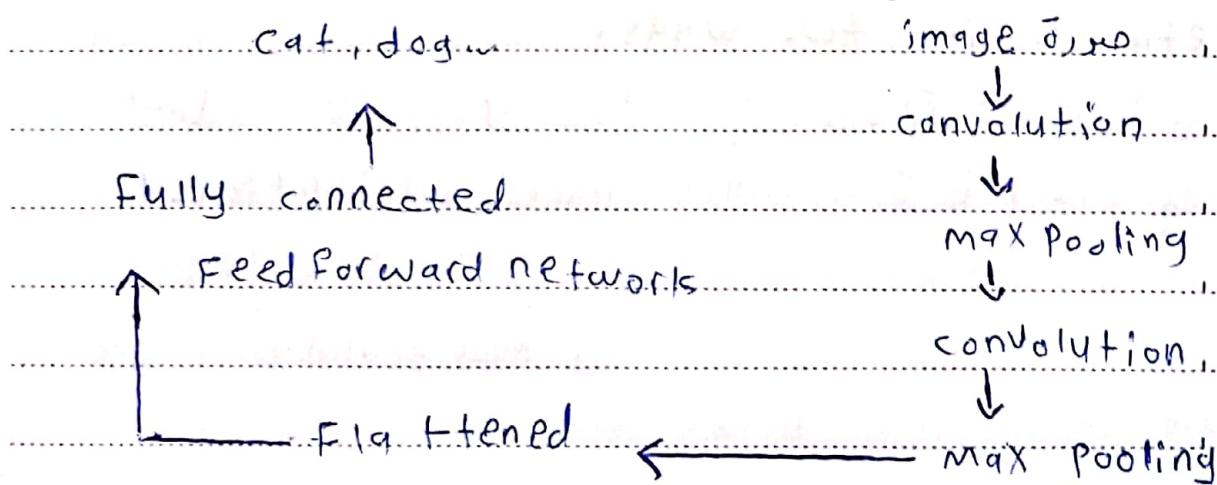
١١) هنا عند زادحة الغار عم يصيغ W. مفرد بالكل الماء

يبدل إلى الأدلة و ثم إزاحة بديعة يصبح الله حضورها يأكلها

الحالات و مثلاً (هذا يعني) معايير الأوزان shared weights

وَهَذِهِ الْطَّرِيقَةُ تَطْبِقُ بِإِرَاكِتَارِيٍّ أَفْلَى ॥

* The whole CNN (pooling)



الى ملة الاولى: convolution

الى ملة الثانية: pooling

تعمل على تضييق حجم العردة الناتجة بعد عملية convolution مع المحافظة على معالمها، وآخر طرق

المستخدم في max pooling ويعتبر هو

الطريقة على تلك أبعاده 2×2 تطبق على العردة المطروحة

وهي كل مرة يطبق على العردة يكون فيه stride = 2

الشكل الذي بين القيم المادية مثلاً:

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

Max
→
Pooling

6	8
3	4

نلاحظ أن هناك في طبقة الـ pooling

* CNN compresses a fully connected network in two ways:

تعمل CNN على ضبط شبكة مفتوحة بالكامل بطيئاً

: الـ weights shared weights، ونفع بها

كامل العردة

Max pooling

المراحل الثالثة flattend: (الخطوة)

يتبع ترتيل المعموقات الناتجة عن pooling دفري تكون

هناك أكثر من مصفوفة في حال كانت هناك أكثر من

فائز في convolution. كل مجموع دايم سيفلا

ترتب عناصر المصفوفة بعد عنصر

$\begin{array}{ c c } \hline 3 & 0 \\ \hline 1 & 3 \\ \hline \end{array}$	$\begin{array}{ c c } \hline -1 & 1 \\ \hline 0 & 3 \\ \hline \end{array}$	\Rightarrow	$\begin{array}{ c c c } \hline 3 & 0 & 1 \\ \hline 1 & -1 & 3 \\ \hline 0 & 3 & -1 \\ \hline \end{array}$
---	--	---------------	---

هذا مرقت طلي

وبالتالي

Flattening 3

* CNN in keras (نظام دراس)

CNN في مكتبة Keras

: convolution عملية ①

model2 = convolution2D(25, 3, 3,

input_shape = (28, 28, 1, 1))

أي تطبق عملية convolution بين صورة الفلاش التي

3x3 أبعادها 28x28 وبين الغلق الذي أبعاده

(25) أبعاد الفلاش وبين الغلق أبعادها 3x3.

وهي حال لم يعط strides فهي (1) ولا يوجد فهو

التاريخ:
الفنان
 $(2.6 \times 2.6 \times 2.5)$ مفري فار:

$$\text{out} = ((N - F + 2P) / \text{strid}) + 1$$
$$= ((28 - 3 + 2 \cdot 0) / 1) + 1 = 26$$

; Max pooling عملية ②

model2.add(maxPooling2D((2, 2)))

هذا سيعتبر العدة كل كل تقليل في العدة باستخدام فلتر 2x2 وبالتأكيد يقل حجم الصورة لكتلة النصف

$$\text{out} = 13 \times 13 \times 2.5$$

; convolution عملية ③

model2.add(convolution2D(50, 3, 3))

3x3 filter convolution عملية تطبيق ابعاد عدد الفلاتر هو 50 وفرها كل فلت

$$\text{out} = ((N - F + 2P) / s) + 1$$
$$= ((13 - 3 + 0) / 1) + 1 = 11$$

عملية التي بين العدة الناتجة عن الـ pooling وبين الفلت

$$(11 \times 11 \times 50)$$

وابي 8 ④

; maxPooling عملية ⑤

model2.add(maxPooling2D((2, 2)))

فلى 2x2 يطبق Max pooling عملية الصورة للنصف

$$\text{out} = (5 \times 5 \times 50)$$

; flatten عملية ⑥

model2.add(Flatten())

التاريخ: / /

ويكون في بعدها ماتع:

$$5 \times 5 \times 50 = 1250$$

Fully connected دالة عاملية في دفل

; Fully connected عاملية ⑥

model2.add(Dense(output_dim=100))

model2.add(Activation('relu'))

model2.add(Dense(output_dim=10))

model2.add(Activation('softmax'))